P-DINA: Model Diagnosis Kognitif Proyek CDA-CDM

P-DINA: model diagnosis kognitif proyek CDA-CDM

Dokumen ini menjelaskan **semua tentang model P-DINA** di proyek ini: idenya, matematikanya, cara training, cara memilih hyperparameter dan kebijakan diagnosis, evaluasi, cara memakai checkpoint, kapan perlu training ulang, bedanya dengan model deep learning seperti YOLO, dan keterbatasannya. Semua angka berasal dari artefak hasil run (`artifacts/`), bukan perkiraan.

Kode: `cdacdm/models.py` (model), `cdacdm/pipeline.py` (training & evaluasi), `cdacdm/evaluation.py` (metrik & seleksi), `cdacdm/diagnosis.py` (label & learning gap), `cdacdm/service.py` (memuat checkpoint & inferensi).

---

1. Ringkasan

Nama	P-DINA — *probabilistic DINA* dengan prior *higher-order*, diestimasi dengan **variational EM**
Tugas	Dari pola jawaban benar/salah siswa, memperkirakan **probabilitas siswa menguasai tiap konsep**
Input	Respons siswa per soal (`1` benar, `0` salah, kosong = tidak dijawab) + Q-matrix (soal → konsep)
Output	Per siswa × konsep: P(mastery), label (`mastered` / `not_mastered` / `uncertain` / `insufficient_evidence`), jumlah bukti
Data training	EEDI NeurIPS 2020 Task 3/4: 3.934 siswa train, 948 soal, 57 konsep (11 konsep aljabar target)
Parameter	2 per soal (guess g, slip s) → 1.896, ditambah 2 per konsep untuk prior (a, b) → 114
Training	CPU, ±30 detik per konfigurasi; seluruh pipeline (12 konfigurasi + baseline + evaluasi) ±9 menit
Kualitas (test, sekali)	ROC-AUC prediksi respons 0,768; ECE 0,008; konsistensi diagnosis split-half 0,876
Checkpoint	`artifacts/model/` (EEDI, data nyata) dan `artifacts_calculus/model/` (kalkulus XI, DUMMY sintetis)

> P(mastery) adalah **estimasi model**, bukan penguasaan yang terbukti. EEDI tidak memiliki data "mastery sebenarnya".

---

2. Intuisi

Bayangkan soal: "*Sederhanakan $3x + 2x$*". Q-matrix menyatakan soal ini menguji satu konsep: **Simplifying Expressions by Collecting Like Terms**.

- Siswa yang **menguasai** konsep itu hampir selalu benar, kecuali **slip** (ceroboh): peluang salah = s.
- Siswa yang **belum menguasai** biasanya salah, kecuali **guess** (menebak benar pilihan ganda): peluang benar = g.

Bila sebuah soal menguji dua konsep, siswa dianggap "siap" hanya bila **menguasai keduanya** (aturan *konjungtif* DINA: *Deterministic Inputs, Noisy "And" gate*).

Dari banyak jawaban, model menimbang bukti: jawaban benar pada soal dengan *g* kecil adalah bukti kuat penguasaan; benar pada soal yang mudah ditebak (*g* besar) adalah bukti lemah. Hasilnya probabilitas per konsep, lengkap dengan seberapa banyak bukti yang mendasarinya.

Q-matrix (948 × 57, biner) adalah pengetahuan pakar yang **tidak dipelajari** model:

Soal	Writing Expressions	Linear Equations	Factorising …	…
Q-101	1	0	0	…
Q-102	0	1	0	…
Q-103 (multi-konsep)	1	1	0	…

Di EEDI, 934 dari 948 soal (98,5%) hanya menguji satu konsep; 14 soal menguji dua konsep.

---

3. Model formal

Untuk siswa *i*, soal *j*, konsep *k*:

```
α_ik ∈ {0,1}                          penguasaan laten (tidak teramati)
η_ij = Π_k α_ik^q_jk                   1 bila siswa menguasai SEMUA konsep yang dibutuhkan soal j
P(X_ij = 1 | α_i) = (1 − s_j)^η_ij · g_j^(1 − η_ij)
```

Prior parameter soal (regularisasi soal dengan sedikit respons): `g_j ~ Beta(1 + κ·0,2 ; 1 + κ·0,8)`, `s_j ~ Beta(1 + κ·0,2 ; 1 + κ·0,8)`. κ (*gs_prior_strength*) dipilih di validation; model terpilih κ = 2 → Beta(1,4 ; 2,6). Batas: $g, s \in [0{,}001 ; 0{,}7]$ dan $g + s \leq 0{,}98$ (soal harus lebih mudah bagi yang menguasai).

Prior penguasaan (dua pilihan, dipilih di validation):

Prior	Rumus	Arti
`independent`	α_ik ~ Bernoulli(λ_k)	tiap konsep punya *base rate* populasi sendiri, antar-konsep independen
`higher_order` (**terpilih**)	α_ik ~ Bernoulli(σ(a_k·θ_i − b_k)), θ_i ~ N(0,1)	ada **kemampuan umum** θ_i; siswa yang kuat di banyak konsep cenderung kuat di konsep lain (HO-DINA, de la Torre & Douglas 2004)

Prior *higher-order* membuat konsep dengan sedikit bukti "meminjam" informasi dari konsep lain milik siswa yang sama.

Missing ≠ salah. Likelihood hanya menjumlahkan respons **teramati** (mask *m_ij*). Soal yang tidak dikerjakan tidak dihitung sebagai salah; konsep tanpa bukti kembali ke prior.

---

4. Training: variational EM

Kenapa tidak EM biasa?

EM DINA klasik menjumlahkan semua profil penguasaan: 2^57 ≈ 1,4 × 10^17 kemungkinan per siswa, mustahil dihitung. P-DINA memakai **pendekatan variasional mean-field**: `q(α_i) = Π_k`

Bernoulli(π_ik). Karena likelihood hanya bergantung pada η_ij, dan di bawah *q* berlaku P(η_ij = 1) = ρ_ij = Π_k π_ik^q_jk, batas bawah log-likelihood (**ELBO**) punya bentuk tertutup:

```
ELBO = Σ_ij m_ij [ρ_ij·ℓ1_ij + (1 − ρ_ij)·ℓ0_ij] − Σ_ik KL(Bern(π_ik) ‖ Bern(λ_ik)) + log
prior(g, s, θ)
ℓ1_ij = x·log(1 − s_j) + (1 − x)·log s_j        (log-likelihood bila η = 1)
ℓ0_ij = x·log g_j      + (1 − x)·log(1 − g_j)   (log-likelihood bila η = 0)
```

Satu iterasi EM

1. **E-step** (perbarui π, keyakinan penguasaan tiap siswa): logit π_ik = logit λ_ik + Σ_j m_ij q_jk (ρ_ij / π_ik)(ℓ1_ij − ℓ0_ij)
   - Untuk soal satu-konsep ρ_ij/π_ik = 1, sehingga update **eksak** (Bayes tepat) dan dihitung dengan dua perkalian matriks. Bila siswa hanya menjawab soal satu-konsep, posterior mean-field = posterior eksak.
   - Untuk 14 soal multi-konsep: iterasi titik-tetap dengan *damping* 0,5, hanya pada blok siswa × konsep yang terdampak.
   - Prior *higher-order*: θ_i diperbarui dengan Newton (estimasi MAP).
2. **M-step** (perbarui parameter soal, rumus tertutup MAP dengan prior Beta):

   ```
   s_j = (Σ_i m·ρ·(1 − x) + a_s − 1) / (Σ_i m·ρ + a_s + b_s − 2)
   g_j = (Σ_i m·(1 − ρ)·x + a_g − 1) / (Σ_i m·(1 − ρ) + a_g + b_g − 2)
   ```

   lalu *g*, *s* dipotong ke batas di atas; parameter prior (λ, atau *a*, *b* untuk *higher-order*) diperbarui (Newton).
3. Hitung ELBO. **Berhenti** bila perubahan relatif ELBO ≤ 10^{-6}, atau setelah 150 iterasi.

Model terpilih konvergen dalam **44 iterasi EM** (ELBO akhir −630.546), ±30 detik di CPU laptop.

Data dan pencegahan kebocoran

- Split **per siswa** (siswa tidak muncul di dua split): train 3.934, validation 492, test 492.
- Model hanya membaca UserId, QuestionId, IsCorrect. Kolom yang bisa membocorkan jawaban (question_pass_rate, prior_accuracy, question_difficulty, student_mean_confidence, …) dikecualikan dan dicatat di artifacts/audit/leakage_audit.json.
- Parameter soal (*g*, *s*) **hanya** dipelajari dari train.

---

5. Seleksi hyperparameter (validation)

Protokol held-out. Pada tiap siswa validation, 20% respons disembunyikan (minimal 5 respons tetap terlihat sebagai konteks). Model menebak penguasaan dari konteks, lalu memprediksi respons yang disembunyikan. Kriteria: **log-loss** (makin kecil makin baik).

Grid: prior {independent, higher_order} × κ {2, 10, 40} × class weighting {tidak, ya} = 12 konfigurasi P-DINA, ditambah baseline. Hasil (artifacts/evaluation/hp_search_validation.csv):

Konfigurasi	Iterasi EM	Waktu fit	Log-loss val	AUC val
higher_order, κ=2, tanpa class weight (terpilih)	44	29,8 s	**0,5721**	0,7648
higher_order, κ=10, tanpa class weight	47	30,1 s	0,5721	0,7647
higher_order, κ=40, tanpa class weight	43	31,3 s	0,5726	0,7644
higher_order, κ=2, dengan class weight	43	28,5 s	0,5742	0,7646

Konfigurasi	Iterasi EM	Waktu fit	Log-loss val	AUC val
independent, κ=2, tanpa class weight	81	9,9 s	0,5788	0,7575
independent, κ=10, tanpa class weight	67	8,1 s	0,5788	0,7576
Q-logistic σ=1 (baseline)	—	21,4 s	0,5735	0,7682
Concept-score k=5 (baseline)	—	0,1 s	0,6233	0,7019
Item-mean (baseline)	—	0,1 s	0,6395	0,6784

Temuan:

- Prior *higher-order* konsisten lebih baik dari *independent* (log-loss 0,572 vs 0,579).
- Kekuatan prior κ hampir tidak berpengaruh: data per soal sudah cukup banyak.
- Class weighting memperburuk log-loss di semua konfigurasi, sehingga tidak dipakai.

---

6. Kebijakan diagnosis (validation)

P(mastery) diubah menjadi label dengan tiga angka, semuanya dipilih dari data validation (`artifacts/model/diagnosis_policy.json`):

Label	Aturan
`insufficient_evidence`	respons pada konsep < **n_min** → **bukan** learning gap, butuh soal tambahan
`mastered`	$\pi \geq \tau + \delta$
`not_mastered` (= **learning gap**)	$\pi < \tau - \delta$
`uncertain`	

- **τ = 0,5** (threshold). Dipilih dari log-loss prediksi DINA berlabel keras pada respons held-out. Nilai terbaik mentah τ = 0,65, tetapi semua $\tau \in [0{,}45 ; 0{,}70]$ berada dalam satu *standard error* dari yang terbaik, sehingga dipilih nilai netral 0,5 (aturan *one-standard-error* ke arah 0,5).
- **n_min = 5** (bukti minimum). Respons tiap siswa dibagi dua secara acak, diagnosis dibuat terpisah dari tiap bagian, lalu dicek kesepakatannya. n_min = nilai terkecil yang mencapai konsistensi ≥ 0,85:

n_min (per paruh)	1	2	3	4	5	6	8
konsistensi	0,837	0,825	0,820	0,839	**0,857**	0,879	0,881

- **δ = 0** (pita ketidakpastian). Konsistensi sudah ≥ 0,85 tanpa pita, sehingga label `uncertain` jarang muncul dengan kebijakan default.

Di aplikasi, τ/δ/n_min bisa diubah di sidebar hanya untuk analisis sensitivitas; aplikasi memberi peringatan bila berbeda dari nilai terpilih.

Learning gap dan prioritas. Konsep target berlabel `not_mastered` adalah *learning gap*. Urutan prioritas: `priority = need × certainty`, dengan `need = (τ − π)/τ` dan `certainty = 1 − entropi(π)`. Konsep jauh di bawah τ dan diagnosisnya yakin didahulukan.

---

7. Evaluasi (test, dijalankan sekali)

Protokol sama dengan validation: 20% respons tiap siswa test disembunyikan; parameter soal dibekukan dari train; test hanya dievaluasi satu kali (pipeline menolak evaluasi ulang dalam run yang sama).

Prediksi respons (492 siswa, 28.003 respons held-out):

Model	ROC-AUC [95% CI]	Log-loss	Brier	Accuracy	F1	ECE
P-DINA (utama)	0,768 [0,759–0,779]	0,568	0,194	0,699	0,704	**0,008**
P-DINA prior independen (ablasi)	0,761 [0,751–0,772]	0,575	0,197	0,693	0,701	0,006
Q-logistic (baseline)	0,775 [0,766–0,786]	0,567	0,193	0,704	0,726	0,036
Concept-score (baseline)	0,718 [0,707–0,733]	0,611	0,213	0,658	0,681	0,016
Item-mean (baseline)	0,672 [0,661–0,682]	0,644	0,226	0,627	0,665	0,005

CI dari bootstrap per siswa (200 ulangan). P-DINA vs Q-logistic: AUC −0,007 [−0,011; −0,003], log-loss +0,001 [−0,003; +0,007] → **setara**. P-DINA dipertahankan karena kalibrasinya jauh lebih baik (ECE 0,008 vs 0,036) dan parameternya bermakna langsung (guess, slip, P(mastery) per konsep), sedangkan Q-logistic adalah model kompensatori tanpa konsep "menguasai/belum".

Kualitas diagnosis (proksi, karena tidak ada mastery sebenarnya):

Ukuran	Hasil	Catatan
Konsistensi split-half (siswa test, konsep target, ≥ 5 respons per paruh)	**0,876** (880 sel)	dua diagnosis independen dari data berbeda sepakat
Akurasi atribut pada **simulasi** dari model terlatih	0,957 (ada bukti) / 0,851 (tanpa bukti)	batas atas optimistis: model diasumsikan benar
Recovery parameter soal (simulasi)	r(g) = 0,965, r(s) = 0,982	prosedur estimasi bisa menemukan kembali parameter yang benar

Prediksi respons yang baik **tidak membuktikan** diagnosis benar; karena itu ketiga ukuran di atas dilaporkan bersama.

---

8. Parameter yang dipelajari

Dari `artifacts/model/item_parameters.csv` (948 soal):

Parameter	Rata-rata	Median	Rentang
guess g	0,338	0,317	0,017 – 0,700
slip s	0,253	0,217	0,002 – 0,700
daya beda $1 - s - g$	0,409	0,417	0,020 – 0,976

- $g \approx 0{,}33$ wajar untuk pilihan ganda 4 opsi (tebakan acak = 0,25). Daya beda sedang, sehingga satu konsep butuh ±5 respons agar diagnosisnya stabil (sesuai n_min).
- 900 dari 948 soal punya parameter andal (≥ 30 respons train). 139 soal target memenuhi syarat untuk form CDA (parameter andal dan daya beda ≥ 0,1).
- Prior *higher-order*: rata-rata $a_k = 3{,}67$, artinya penguasaan antar-konsep sangat terkait dengan kemampuan umum θ.

---

9. Inferensi untuk siswa baru (tanpa training ulang)

Untuk siswa yang tidak ada di data training, `PDINA.infer()` hanya menjalankan **E-step** dengan *g*, *s*, dan parameter prior **dibekukan**:

- Bisa untuk tes parsial atau tidak lengkap; soal kosong = tidak teramati.
- Hasil per konsep: `mastery_prob` (π), `mastery_label`, `n_evidence`, `n_correct`, `prior_mastery_prob`, `posterior_sd` (= √(π(1−π)), ukuran ketidakpastian Bernoulli, **bukan** interval kepercayaan), `entropy_bits`.
- Konsep tanpa respons mengembalikan prior (dengan prior *higher-order*, prior ini sudah disesuaikan θ siswa) dan berlabel `insufficient_evidence`.
- Cepat: diagnosis 30 siswa demo ±0,4 detik.

Soal yang dipakai harus **ada di item bank** checkpoint (QuestionId dikenal); soal yang tidak dikenal ditolak validasi input.

---

10. Cara memakai

Memakai checkpoint (paling umum)

```
from cdacdm.api import load_model, predict_mastery
import pandas as pd

svc = load_model("artifacts")                        # memuat artifacts/model, tanpa training
resp = pd.DataFrame({"student_id": ["S1"] * 3, "QuestionId": [12, 345, 678], "response": [1, 0,
""]})
prof = predict_mastery(resp, service=svc)            # profil per siswa × konsep
res = svc.diagnose(resp)                             # profil + learning gap + ringkasan kelas +
rekomendasi
report = svc.report_json(res)                        # ringkasan JSON (dengan disclaimer)
```

Format CSV lain (lebar, `answer_option` 1–4) dijelaskan di `README_streamlit.md`. Di aplikasi Streamlit, semua ini lewat halaman *Student Assessment* dan *Learning Gap Analysis*.

Training ulang

```
python -m cdacdm.pipeline --output-dir artifacts_new     # semua langkah, ±9 menit CPU
python -m cdacdm.pipeline --fast --output-dir tmp_smoke  # grid kecil, untuk uji cepat
python -m cdacdm.dummy_calculus                          # checkpoint kalkulus DUMMY
(artifacts_calculus)
```

Atau jalankan `cda_cdm_model_training.ipynb` (lokal / Colab). Pipeline: audit data → Q-matrix & konsep target → seleksi hyperparameter (train → validation) → kebijakan diagnosis (validation) → **evaluasi test sekali** → kualitas diagnosis (split-half, simulasi) → form CDA → diagnosis siswa test → demo pre/post → simpan checkpoint.

> Pakai `--output-dir` ke folder baru untuk eksperimen. Menjalankan ulang ke `artifacts/` menimpa checkpoint dan menghitung ulang angka test; jangan lakukan hanya untuk "memperbarui" hasil. Konfigurasi ada di `configs/experiment.json` (grid, prior, batas iterasi, aturan evaluasi).

Isi checkpoint (`artifacts/model/`)

File	Isi
`pdina_params.npz`	Q-matrix, *g*, *s*, λ, *a*, *b*, `question_ids`, `concept_ids`

File	Isi
`pdina_config.json`	hyperparameter, jumlah iterasi EM, ELBO akhir, konfigurasi asal
`diagnosis_policy.json`	τ, δ, n_min, konsep target, dan asal-usul pemilihannya
`item_parameters.csv`	parameter per soal (guess, slip, daya beda, kelayakan)
`concept_metadata.csv`, `target_concept_map.csv`	nama konsep, cakupan target, prasyarat, urutan kurikulum
`item_bank.csv`, `q_matrix.csv`	item bank & Q-matrix yang dipakai
`intervention_map_resolved.csv`	peta intervensi (placeholder)
`model_card.json`, `experiment_config_used.json`	ringkasan run & konfigurasi lengkap

Saat dimuat, `CDMService.load()` memeriksa bahwa QuestionId, urutan konsep, dan konsep target saling konsisten.

---

11. Kapan perlu training ulang?

Situasi	Training ulang?	Alasan
Siswa baru mengerjakan soal yang sudah ada di item bank	**Tidak**	cukup inferensi (E-step)
Mengubah τ / δ / n_min	Tidak	hanya kebijakan label; idealnya dipilih ulang di validation
Mengubah intervention map	Tidak	bukan bagian model
Menambah **soal baru**	**Ya**	*g*/*s* soal baru harus dikalibrasi dari respons (≥ 30 respons/soal)
Mengubah **Q-matrix** atau daftar konsep (mis. topik SMA baru)	**Ya**	struktur model berubah
Memakai **populasi lain** (kelas SMA penelitian)	**Ya / validasi ulang**	parameter EEDI berasal dari siswa SMP UK
Checkpoint kalkulus untuk penelitian sungguhan	**Ya**	saat ini dilatih dengan data DUMMY sintetis

---

12. P-DINA vs model deep learning (mis. YOLO)

Aspek	YOLO (deteksi objek)	P-DINA
Jenis belajar	*Supervised*: ribuan gambar berlabel kotak	**Variabel laten**: mastery tidak pernah diamati, disimpulkan dari jawaban benar/salah
Yang dipelajari	Jutaan bobot jaringan saraf	±2.000 parameter bermakna (*g*, *s* per soal; *a*, *b* per konsep)
Struktur	Dipelajari dari data	Ditentukan teori dan pakar (Q-matrix + aturan konjungtif DINA)
Algoritme	Gradient descent + backprop, banyak epoch	Variational EM dengan update tertutup, ±44 iterasi
Komputasi	GPU, jam–hari	CPU, ±30 detik per fit
Evaluasi	Dibandingkan dengan label (mAP, IoU)	Tidak ada label mastery → prediksi respons held-out, split-half, simulasi

Aspek	YOLO (deteksi objek)	P-DINA
Interpretasi	*Black box*	Langsung: "soal ini mudah ditebak (g = 0,6)", "P(mastery) = 0,23 dari 7 respons"
Data baru	*Forward pass*	E-step kecil per siswa, parameter tetap

Konsekuensinya, P-DINA ringan, transparan, dan cocok untuk keputusan pendidikan, tetapi kualitasnya bergantung pada ketepatan Q-matrix dan asumsi DINA, serta tidak bisa diverifikasi terhadap "jawaban benar" seperti YOLO.

---

13. Asumsi dan keterbatasan

- **Konjungtif**: soal multi-konsep dianggap butuh *semua* konsepnya. Bila sebenarnya kompensatori, model terlalu ketat (hanya 14 soal EEDI yang terdampak).
- **Q-matrix dianggap benar.** Audit visual 22 soal fokus: 17 cocok, 5 hanya parsial (README utama). Kesalahan Q-matrix langsung menjadi kesalahan diagnosis.
- **Mastery statis**: model tidak memodelkan belajar selama tes; perubahan antar-waktu dianalisis terpisah (pre/post).
- **Independensi lokal**: jawaban dianggap independen bila mastery diketahui.
- **Pendekatan mean-field**: eksak untuk soal satu-konsep, aproksimasi untuk soal multi-konsep; θ adalah estimasi titik (MAP), sehingga ketidakpastian θ tidak ikut dihitung.
- **`posterior_sd` bukan interval kepercayaan**; ketidakpastian parameter soal tidak dirambatkan ke π.
- **Tidak ada ground truth mastery** di EEDI; kualitas diagnosis hanya proksi (bagian 7).
- **Populasi**: EEDI mayoritas siswa SMP di UK dan tidak memuat kalkulus. Belum ada validasi pada kelas SMA penelitian.
- **Konsep dengan sedikit soal** (mis. *Gradient Between Two Co-ordinates*, 2 soal) tidak dapat didiagnosis dengan n_min = 5.
- Q-logistic sedikit lebih unggul AUC-nya; trade-off ini sengaja dilaporkan (bagian 7).

---

14. Referensi

- Junker, B. W., & Sijtsma, K. (2001). Cognitive assessment models with few assumptions, and connections with nonparametric item response theory. *Applied Psychological Measurement*, 25(3), 258–272. (model DINA)
- de la Torre, J., & Douglas, J. A. (2004). Higher-order latent trait models for cognitive diagnosis. *Psychometrika*, 69(3), 333–353. (prior *higher-order*)
- Blei, D. M., Kucukelbir, A., & McAuliffe, J. D. (2017). Variational inference: A review for statisticians. *Journal of the American Statistical Association*, 112(518), 859–877. (inferensi variasional)
- Wang, Z., et al. (2020). Instructions and guide for diagnostic questions: The NeurIPS 2020 Education Challenge. arXiv:2007.12061. (data EEDI)

Lihat juga: `README.md` (gambaran proyek & setup), `README_streamlit.md` (aplikasi), `README_slm.md` (laporan naratif).